

UE : Bioinformatique pour la Génomique

Rapport Projet Annotation

- Annotation d'un fragment génomique -



Master Bioinformatique et Biologie des systèmes
Année Universitaire : 2024-2025

1. Introduction :

L'établissement de la séquence d'un génome constitue la première étape cruciale pour comprendre son fonctionnement. Grâce aux avancées du séquençage de nouvelle génération (NGS), cette étape, autrefois limitante, est désormais réalisable à grande échelle. Cependant, elle nécessite une infrastructure appropriée et des compétences bio-informatiques pointues pour reconstruire ce puzzle génomique. À l'issue de cette séquence, nous obtenons une série de nucléotides (A, T, C et G) qui, prise isolément, ne révèle pas de signification évidente. C'est ici qu'intervient l'annotation génomique, un processus fondamental en biologie moléculaire et en génomique, qui permet de déterminer la structure et la fonction des gènes au sein d'un génome.

L'annotation génomique se divise en deux niveaux complémentaires : l'annotation structurale, qui identifie les zones fonctionnelles du génome, telles que les gènes codant pour des protéines, les ARN ribosomiques (ARNr) et les ARN de transfert (ARNt), ainsi que les ARN non codants, comme les ARN antisens et les petits ARN (ARNs), en utilisant des bases de données comme Rfam. Elle inclut également l'identification des éléments régulateurs, tels que les promoteurs et les terminateurs de transcription, facilitant ainsi la prédiction de la structure en unités de transcription, particulièrement chez les bactéries.

Le second niveau, l'annotation fonctionnelle, vise à déterminer les rôles des gènes identifiés. Pour les gènes codant pour des protéines, cela se fait par des recherches de similarité de séquences à l'aide d'outils comme BLAST, ainsi que par l'analyse de la présence de domaines fonctionnels via des programmes tels que InterProScan et HMMsearch. En ce qui concerne les ARNt et les ARNr, l'annotation inclut également leur classification par type (par exemple, ARNt^{Ser}, ARNt^{Leu}, ARNr 16S, ARNr 23S, ARNr 5S) et leur appartenance à des sous-familles d'ARN non codants.

L'annotation génomique revêt une importance capitale non seulement pour appréhender la complexité et le fonctionnement des génomes, mais aussi pour servir de fondement à de nombreuses analyses génomiques. Elle guide les travaux expérimentaux en permettant de prédire des caractéristiques phénotypiques et en identifiant les relations entre les différents éléments génomiques. En fournissant des références détaillées sur les divers produits d'un génome, les annotations génomiques facilitent des analyses bio-informatiques variées, telles que le traitement des données de séquençage ARN (RNA-seq). Cependant, il convient de souligner que l'annotation génomique est un processus complexe qui nécessite des outils bio-informatiques avancés ainsi qu'une expertise en génomique fonctionnelle. De plus, le choix des méthodes d'annotation peut introduire des biais dans les analyses, renforçant l'importance de considérer l'annotation comme un paramètre expérimental essentiel en bio-informatique. Ainsi, une annotation précise et fiable est indispensable pour optimiser la valeur des données génomiques et progresser dans notre compréhension des mécanismes biologiques sous-jacents.

2.Problématique :

Lactococcus lactis, une bactérie du groupe des Bacillota, joue un rôle crucial dans l'industrie alimentaire, notamment dans la fabrication de produits laitiers fermentés tels que le yaourt et le fromage. Son utilisation en tant que probiotique et agent de fermentation souligne l'importance d'une compréhension approfondie de ses mécanismes biologiques et biochimiques. L'analyse de son génome offre une occasion unique d'explorer ses interactions avec d'autres organismes et son rôle au sein des communautés microbiennes.

Ce projet se concentre sur l'annotation d'un fragment génomique de *L. lactis*, visant à identifier et caractériser les gènes présents, ainsi qu'à analyser leurs fonctions potentielles et leur localisation cellulaire. Classiquement, chez les procaryotes, la prédiction des gènes codant pour des protéines (CDS) débute par la recherche de phases ouvertes de lecture. Chez *Lactococcus lactis*, les codons d'initiation de la traduction sont généralement similaires à ceux trouvés chez d'autres bactéries, avec AUG comme codon le plus commun, codant pour la méthionine. Cependant, GUG et UUG peuvent également servir d'initiateurs dans certaines circonstances, bien que moins fréquemment.

Pour ce faire, des approches bioinformatiques avancées seront adoptées, notamment l'utilisation de matrices de poids positionnels (PWM) dérivées de *Bacillus subtilis*, en raison de leurs similarités phylogénétiques. L'emploi d'outils tels que GeneMark et scan_for_matches facilitera l'identification des gènes potentiels, tout en posant des défis tels que la sélection adéquate des codons de départ et l'interprétation des résultats. Cette étude s'interroge sur la pertinence et l'efficacité des méthodes employées pour annoter les gènes de *Lactococcus lactis*, cherchant à comprendre dans quelle mesure ces méthodes peuvent fournir des prédictions fonctionnelles fiables.

De plus, cette recherche vise à enrichir la connaissance des génomes bactériens en général, en mettant en lumière les voies métaboliques et les interactions écologiques au sein des communautés microbiennes.

3.Méthodologie :

Pour réaliser l'annotation génomique de *Lactococcus lactis*, on a d'abord procédé à une cartographie initiale pour identifier les cadres ouverts de lecture (ORF) en utilisant l'outil ORFfinder. Cet outil analyse les six phases de lecture (trois sur le brin direct et trois sur le brin complémentaire) pour détecter les ORF, définis comme des séquences comprises entre un codon initiateur et un codon stop. Cependant, il est important de noter que ORFfinder ne repose pas sur une méthode statistique, ce qui signifie qu'il ne calcule pas la probabilité qu'une séquence soit codante. La seule valeur seuil appliquée est la taille minimale de l'ORF, qu'on a fixée à 300 nucléotides, car généralement, les ORF de plus de 100 codons (300 pb) sont considérés comme potentiellement codants. Des analyses statistiques antérieures ont montré que, bien que des gènes de taille

inférieure à 100 codons existent, la majorité des petits ORF sont souvent des faux positifs.

Conscient des limites de cette approche, deux méthodes statistiques ont été utilisées pour identifier les régions codantes potentielles, appelées CDS (CoDing Sequences). La première méthode, GeneMark, s'appuie sur un modèle de Markov. GeneMark analyse la séquence en déplaçant une fenêtre de taille choisie avec un pas défini, fournissant deux types de sorties : une sortie graphique qui indique pour chaque fenêtre la probabilité d'être codée, et une sortie textuelle filtrée selon un seuil de probabilité moyenne d'être codante entre un codon initiateur potentiel et un codon stop. Cependant, le choix du codon de départ peut poser des problèmes, car plusieurs options peuvent exister dans une petite région, et la probabilité associée au codon de départ dans GeneMark ne peut pas être utilisée efficacement, car le modèle de recherche de Ribosome Binding Site (RBS) qu'il implémente est celui de *Escherichia coli*. Pour surmonter cela, on a conservé plusieurs choix et espéré affiner la sélection plus tard en recherchant la position du RBS avec `scan_for_matches`. Il est crucial de se référer à la sortie graphique, car la localisation précise du codon de départ ne peut être déterminée qu'après que la courbe de probabilité indique que la séquence est codante.

La seconde méthode, GeneMark.hmm, permet une analyse plus sophistiquée en intégrant des usages de code différents dans une même recherche. Elle distingue entre les gènes typiques, supposés hérités verticalement de la cellule mère, et les gènes atypiques, acquis par transfert horizontal. Dans cette méthode, les résultats graphiques présentent deux courbes : la courbe noire représente les prédictions réalisées avec la table standard de l'organisme, tandis que la courbe rouge est basée sur l'apprentissage à partir du fragment analysé. La sortie textuelle est simplifiée, ne proposant qu'une seule position de codon de départ, ce qui facilite l'interprétation des résultats.

Pour affiner la recherche des codons de départ, on a utilisé `scan_for_matches` pour détecter la présence d'un RBS en amont des codons de départ retenus. On a d'abord réalisé une recherche en utilisant un consensus strict pour le RBS, en cherchant un motif en amont d'un codon initiateur (ATG, GTG ou CTG). Étant donné que les motifs ne sont généralement pas conservés à 100 %, on peut également effectuer une recherche avec un motif dégénéré pour accepter des substitutions.

Ensuite, on a appliqué une troisième recherche en utilisant une matrice de poids-positions (PWM) pour améliorer l'identification des RBS. La syntaxe correspondante a permis de remplacer le motif par une matrice représentant "la fréquence" de chaque base à chaque position du motif. Les valeurs de la matrice sont calculées comme suit : $\log_2(fb,i / Pb) \times 10$, où fb,i est la fréquence observée de la base b à la position i dans toutes les séquences et Pb est la fréquence de cette base dans l'ensemble du génome. En ajustant le seuil de la matrice, on peut identifier une majorité de RBS avec moins de faux positifs, ce qui peut considérablement améliorer la capacité de détection. Mais cette approche repose sur la qualité des matrices utilisées et donc elle peut négliger des motifs non conservés.

Pour identifier les unités de transcription, on a également mené des recherches sur les promoteurs et les terminateurs. En ce qui concerne les promoteurs de type sigma A, on

peut noter qu'ils contiennent généralement deux régions conservées à environ -35 pb et -10 pb du site d'initiation de la transcription.

En complément de l'annotation structurale, on a mis en place une annotation fonctionnelle en utilisant BlastP pour la recherche par similarité, ce qui va permettre d'identifier des homologues protéiques et d'inférer des fonctions basées sur des séquences connues. Cependant, cette méthode dépend fortement de la richesse et de l'actualité des bases de données.

Pour approfondir la compréhension des protéines, on a également utilisé des outils comme InterProScan et/ou CD-Search pour détecter des domaines fonctionnels, bien que la précision de ces analyses puisse être affectée par la qualité des annotations existantes. Enfin, pour évaluer la localisation cellulaire et identifier les fragments transmembranaires, on a employé SignalP et DeepTMHMM. Ces outils sont essentiels pour prédire les signaux de sécrétion, mais peuvent présenter des taux de faux positifs, notamment dans des séquences non conventionnelles. Ensemble, ces méthodes nous fournissent une approche intégrée et robuste pour l'annotation du génome de *Lactococcus lactis*, tout en tenant compte des limites associées à chaque technique.

4. Résultats :

I. Résultats obtenus avec ORFFinder :

L'analyse réalisée avec ORF Finder a été configurée selon plusieurs critères essentiels: une taille minimale de l'ORF à 300 pb, en incluant les codons initiateurs « ATG » ainsi que d'autres codons d'initiation alternatifs. De plus, l'option « Ignore nested ORFs » a été cochée pour s'assurer que les ORF complètement incluses dans une plus grande ORF soient ignorées.

Suite à cette configuration, ORF Finder a identifié un total de cinq ORF, toutes situées sur le brin direct. Une diversité a été observée dans les tailles des ORF, la plus longue étant ORF3 avec 2982 nt, tandis que la plus courte est ORF5 avec 738 nt.

ORF3 +	frame : 2	start : 455	stop : 3436	length (nt aa): 2982 993
ORF2 +	frame : 1	start : 7261	stop : 9270	length (nt aa): 2010 669
ORF4 +	frame : 3	start : 3447	stop : 5249	length (nt aa): 1803 600
ORF1 +	frame : 1	start : 5230	stop : 6486	length (nt aa): 1257 418
ORF5 +	frame : 3	start : 6483	stop : 7220	length (nt aa): 738 245




Figure 1 : Résultats de l'analyse ORFFinder

II.Résultats Obtenus avec GeneMark & GeneMark.hmm :

Pour les analyses réalisées avec GeneMark et GeneMark.hmm, le modèle d'organisme choisi était *Lactococcus lactis* II1403. Pour GeneMark, le paramètre "window size" a été modifié à 120 pb, au lieu des 96 pb par défaut. Deux seuils de probabilité moyenne d'être codant ont été utilisés : un premier seuil de 0.5 et, dans une seconde analyse, un seuil de 0.4.

Synthèse des résultats :

	ORFfinder	GM 0.5	GM 0.4	GM.hmm
CDS tronquée	<300nt	-	-	174 - 347
CDS1	455 - 3436	455	455	455
CDS2	3447- 5249	3447	3447	3447
CDS3	5230- 6486	5230 / 5239/5242	5230/ 5239/5242	5242
CDS4	6483 -7220	6483	6483	6483
CDS5	7261- 9270	7222	7222	7222
CDS 6	<300nt (pas trouvé)	9406/9409	9406/9409	9475

Figure 2 : Synthèse des résultats des approches ORFfinder, GeneMark et GeneMark.hmm

Analyse des résultats de GeneMark

a. Sortie graphique :

Les courbes générées montrent la probabilité d'être codante pour chaque fenêtre de séquence. Les pics indiquent des régions avec une forte probabilité d'être codantes, tandis que les vallées suggèrent des zones non codantes.

Pour l'identification des ORF, il faut localiser les régions avec des probabilités élevées et identifier les CDS potentielles en fonction des seuils prédéfinis.

b. Sortie textuelle :

Les résultats sont filtrés pour ne retenir que les CDS qui dépassent le seuil de probabilité minimal.

Il est important de noter les codons de départ proposés par GeneMark ainsi que les positions des codons stop. Ces informations permettront de comparer les résultats avec d'autres approches d'annotation génomique.

Analyse des résultats de GeneMark.hmm

a. Sortie graphique :

L'interprétation des deux courbes générées fournit des indices sur la performance du modèle par rapport aux données. La courbe standard représente la prédiction basée sur le modèle d'apprentissage, tandis que la courbe ajustée reflète les prédictions sur le fragment analysé.

Pour identifier les régions codantes, il est essentiel de rechercher les régions avec des probabilités élevées d'être codantes, similaires à l'approche utilisée avec GeneMark.

b. Sortie textuelle :

GeneMark.hmm propose des codons de départ avec une précision améliorée, ce qui permet une identification plus fiable des ORF.

En outre, cet outil fournit des informations sur les gènes typiques (hérités verticalement) et les gènes atypiques (potentiellement acquis par transfert horizontal)

Pour trancher entre les différentes possibilités de codons start retenues à l'issue de l'analyse des résultats des différentes méthodes statistiques de détection de régions codantes, nous allons donc rechercher la présence d'un RBS en amont d'un des codons start retenus. Pour cela nous allons utiliser scan-for-matches.

III. Résultats obtenus avec Scan_for_matches :

La principale difficulté demeure la localisation des codons initiateurs des régions codantes. Chez les procaryotes, l'initiation de la traduction se fait après association du ribosome avec une région contenant un site de fixation pour la petite sous unité du ribosome. Cette région (Ribosome Binding Site ou RBS) renferme une séquence complémentaire de l'extrémité 5' de l'ARN 16S (le Shine-Dalgarno: 5'-AAGGAGGTG-3'). Cette séquence contient généralement le motif GGAGG 5 ou 12 bases du codon initiateur (des distances plus grandes ou plus petites ont été observées). La région ne doit pas renfermer de structure secondaire stable.

Première recherche : le consensus strict du RBS:

Motif recherché : GGAGG 5 à 12 pb en amont d'un codon initiateur soit ATG, GTG ou GTG

Syntaxe scan_for_matches : GGAGG 5...12 DTG

Résultats :

>seq_L_lactis_lactis : [161,176] GGAGG CACTCAAA ATG

>seq_L_lactis_lactis : [6469,6485] GGAGG GAAGAGGAA ATG

>seq_L_lactis_lactis : [8071,8086] GGAGG GTTTGATA ATG

>seq_L_lactis_lactis : [9397,9411] GGAGG TAAAGTG GTG

Les résultats de la recherche du consensus strict du RBS révèlent plusieurs occurrences du motif GGAGG situées entre 5 et 12 pb en amont des codons initiateurs. Parmi celles-ci, les séquences >seq_L_lactis_lactis : [161,176] et >seq_L_lactis_lactis : [9397,9411] correspondent toutes deux au motif recherché, mais présentent une taille inférieure à 300 nt, ce qui soulève des doutes quant à leur capacité à confirmer efficacement la position des codons initiateurs. Il serait donc prudent de les conserver pour d'autres analyses, mais avec réserve. En revanche, la séquence >seq_L_lactis_lactis : [6469,6485] répond aux critères de localisation et de séquence, ce qui en fait un bon candidat pour confirmer la position du codon initiateur. La séquence >seq_L_lactis_lactis : [8071,8086], quant à elle, a été exclue comme faux positif, étant localisée dans une région prédite comme codante.

>seq_L_lactis_lactis : [161,176]
GGAGG CACTCAAA ATG : confirme la position 174 du codon initiateur de la 1ère CDS, maison considère que c'est une CDS tronquée.

>seq_L_lactis_lactis : [6469,6485]
GGAGG GAAGAGGAA ATG : confirme la position 6483 du codon initiateur de la CDS 4.

>seq_L_lactis_lactis : [9397,9411]

GGAGG TAAAGTG GTG : confirme la position 9409 du codon initiateur de la CDS 6.

Étant donné que les motifs ne sont généralement pas conservés à 100 % et peuvent présenter certaines variations par rapport au consensus, il est pertinent d'élargir la recherche en utilisant un motif dégénéré qui accepte des substitutions.

Deuxième recherche : motif dégénéré

Syntaxe scan_for_matches : GGAGG[1,0,0] 5...12 DTG

Résultats : 35 motifs obtenus dont :

>seq_L_lactis_lactis:[161,176] : GGAGG CACTCAAA ATG ~> confirme le start en 174
>seq_L_lactis_lactis:[443,457] : AGAGG AAAAAAC ATG ~> confirme le start en 455
>seq_L_lactis_lactis:[3434,3449] : TGAGG ACTAATAG ATG ~> confirme le start en 3447
>seq_L_lactis_lactis:[5231,5244] : TGAGG ATAATG ATG ~> confirme le start en 5242
>seq_L_lactis_lactis:[6469,6485] : GGAGG GAAGAGGAA ATG ~> confirme le start en 6483
>seq_L_lactis_lactis:[7205,7224]:GAAGG TAGGAACTAGA GTG~>confirme le start en 7222
>seq_L_lactis_lactis:[9397,9411] : GGAGG TAAAGTG GTG ~>confirme le start en 9409

Les RBS identifiés avec le consensus strict sont également retrouvés avec le motif dégénéré, ce qui permet de renforcer la validité des résultats. Toutefois, de nombreux faux positifs ont été observés parmi les 35 motifs obtenus. Parmi les résultats, presque tous les codons initiateurs des CDS ont pu être confirmés grâce à cette recherche.

Troisième recherche : utilisation d'une matrice poids-positions (PWM):

Syntaxe scan_for_matches : {(-23, -53, 20, -33), (-22, -34, 20, -46), (14, -46, -7, -15), (-27, -52, 19, -17), (-4, -17, 14, -10)} > 44 5...12 DTG

Résultats : 23 motifs identifiés dont :

>seq_L_lactis_lactis:[161,176] : GGAGG CACTCAAA ATG
>seq_L_lactis_lactis:[6469,6485] : GGAGG GAAGAGGAA ATG
>seq_L_lactis_lactis:[7205,7224] : GAAGG TAGGAACTAGA GTG
>seq_L_lactis_lactis:[9397,9411] : GGAGG TAAAGTG GTG

En réduisant le seuil (par exemple, en passant de 44 à une valeur plus basse), on peut accroître la sensibilité de la recherche, ce qui permet de détecter des RBS moins fortement représentés par le consensus. Cela peut augmenter le nombre de motifs identifiés, mais aussi le risque de faux positifs.

syntaxe scan_for_matches : {(-23, -53, 20, -33), (-22, -34, 20, -46), (14, -46, -7, -15), (-27, -52, 19, -17), (-4, -17, 14, -10)} > 40 5...12 DTG

On a obtenu les mêmes résultats qu'avec un seuil de 44, en ajoutant :

>seq_L_lactis_lactis:[443,457] : AGAGG AAAAAAC ATG

En abaissant le seuil à 30 :

syntaxe scan_for_matches : {(-23, -53, 20, -33), (-22, -34, 20, -46), (14, -46, -7, -15), (-27, -52, 19, -17), (-4, -17, 14, -10)} > 40 5...12 DTG

on a réussi à identifier toutes les CDS, y compris :

>seq_L_lactis_lactis:[3434,3449] : TGAGG ACTAATAG ATG

>seq_L_lactis_lactis:[5231,5244] : TGAGG ATAATG ATG

On voit que la matrice peut être un bon compromis car identifie une majorité de RBS avec moins de faux positifs.

Synthèse en incluant les RBS donc avec identification du bon codon start :

	ORFfinder	GM 0.5	GM 0.4	GM.hmm	Bon start
CDS1	455 - 3436	455	455	455	455
CDS2	3447- 5249	3447	3447	3447	3447
CDS3	5230 6486	5230 / 5239/5242	5230 / 5239/5242	5242	5242
CDS4	6483 -7220	6483	6483	6483	6483
CDS5	7261 9270	7222	7222	7222	7222
CDS 6	<300nt (pas trouvé)	9406/9409	9406/9409	9475	9409

Figure 3 : Synthèse des résultats des approches ORFfinder, GeneMark, GeneMark.hmm, et confirmation des codons start grâce à scan for matches

On obtient les résultats suivant :

CDS1 : 455 - 3436 frame + 2

CDS2 : 3447- 5249 frame + 3

CDS3 : 5242- 6486 frame + 1

CDS4 : 6483 -7220 frame + 3

CDS5 : 7222-9270 frame + 1

Identification des unités de transcription : recherche des promoteurs et terminateurs de transcription :

1. Recherche des promoteurs de type sigma A :

L'analyse d'un grand nombre de promoteurs reconnus par sigmaA montre qu'ils contiennent généralement deux régions bien conservées à environ -35 pb et -10 pb du site d'initiation de la transcription. Ces deux séquences sont séparées par 16 à 35 nucléotides. Les bases les plus souvent observées dans ces régions sont TTGACA pour la -35 et TATAAT pour la -10.

Recherche des motifs consensus stricts :

Syntaxe scan-for-matches : TTGACA 16...35 TATAAT

Cette recherche ne donne aucun résultat. C'est ce que l'on observe souvent lors de l'identification de ces promoteurs car il est rare que dans les séquences « réelles », celles-ci suivent le consensus pour chacun des motifs. La dégénérescence des séquences de ces motifs étant utilisée par l'organisme pour faire une régulation fine des gènes transcrits

Recherche avec une matrice poids/positions (PWM) :

Syntaxe scan_for_matches : {(-22,-29,-25,16),(-18,-25,-21,16),(-28,-17,18,-11),(12,-9,-19,-6),(-2,12,-15,-7),(9,-13,-10,-1)} > 50 16...35

{(-32,-29,-45,17),(17,-45,-45,-28),(-3,-9,-21,11),(14,-7,-19,-21),
(14,-7,-19,-20),(-28,-35,-45,17)} > 50

Résultats obtenus :

```
>seq_L_lactis_lactis:[111,151] : TTGCCA TCAATGCTCAGGACGAATATTGCATGATC TATCAT
>seq_L_lactis_lactis:[272,304] : TTGTAA AACAGGAGCTCTGATGGGTTG TAACAT
>seq_L_lactis_lactis:[1175,1218]:TTGACT AAAGTTGAAGCAATAGATGAAGATAAAAAATA
TATAAT
>seq_L_lactis_lactis:[1527,1561]:TTGATT CTACATTTGGCATAGGAGCTCCA TATAAT
>seq_L_lactis_lactis:[2123,2152]:TTGAAA TTCTACATTACAAGCATG TACAAT
>seq_L_lactis_lactis:[3793,3830] :TTGAAT TAAGTGATTATGAGCAGGCTGATATG TATAAT
>seq_L_lactis_lactis:[4242,4279]:TTGAAT TTGATAAATATTCTTACGATATTTGC TATGAT
>seq_L_lactis_lactis:[5103,5131]:TTGAAT GCTGCCAGAAAAGCAAA TAAAT
>seq_L_lactis_lactis:[5338,5369]:TTGACT CTCTCTACAGGATTGCCTGG TATAAT
>seq_L_lactis_lactis:[6571,6605]:TTGACG AAGGAAGTTATACTAATTTTATT TATGAT
>seq_L_lactis_lactis:[9317,9353]:TTGACT TCCGCTTGAAATCACTTGAGCATTC TACAAT
```

On ne retiendra que :

```
>seq_L_lactis_lactis:[272,304] : TTGTAA AACAGGAGCTCTGATGGGTTG TAACAT
>seq_L_lactis_lactis:[9317,9353]:TTGACT TCCGCTTGAAATCACTTGAGCATTC TACAAT
```

Les autres étant clairement des faux positifs car localisés en pleine région prédite comme codante. En effet, sans validation expérimentale, nous ne pouvons pas par simple prédiction conserver les promoteurs trouvés au sein de régions codantes.

2. Recherche des terminateurs indépendants:

Il nous faut donc rechercher une structure secondaire de type tige boucle suivie d'un poly T. Pour cela nous allons donc utiliser les patterns suivants :

$r1=\{AU,UA,GC,CG,GU,UG,GA,AG\}$
 $p1 = 3...5$ $p2 = 3...10$ $3...9$ $r1 \sim p2$ $\sim p1$ TTTTTT[1,0,0]

Résultats obtenus :

```
>seq_L_lactis_lactis:[29,59]:AAC CCCGG ATGAGAATT CCGGG GTT TTTTTC
>seq_L_lactis_lactis:[557,582] : ACT GTA AGTAAAAA TAA AGT TTTTTT
>seq_L_lactis_lactis:[1771,1800] : AAA GGAGT ATGAAAAA GATAT TTT TATTTT
>seq_L_lactis_lactis:[3986,4009] : AGT ATT ATCTTT GGT ACT TTTTCT
>seq_L_lactis_lactis:[4404,4424] : TTG TTT ATG GAA CAA CTTTTT
>seq_L_lactis_lactis:[6683,6717] : GTT GATTGTT GACATGAAA AGTGAGA AAC TTTTAT
>seq_L_lactis_lactis:[7224,7248] : GAA AAA AATACTA GGT TTC CTTTTT
>seq_L_lactis_lactis:[8162,8183] : TTA CAG CAAA TGG TAA TATTTT
>seq_L_lactis_lactis:[8670,8696] : TAA ATT TGTCAGTCA GGG TTA TTATTT
>seq_L_lactis_lactis:[9277,9310] : GAA AAAGGGT GGGAATCC ACTCTTT TTC TTTTTT
```

Les résultats qui sont retenus:

```
>seq_L_lactis_lactis:[29,59]:AAC CCCGG ATGAGAATT CCGGG GTT TTTTTC
>seq_L_lactis_lactis:[9277,9310] : GAA AAAGGGT GGGAATCC ACTCTTT TTC TTTTTT
les autres sont des faux positifs car dans région codante.
```

Donc à ce stade de l'analyse, on peut proposer une cartographie en CDS de notre fragment génomique ainsi que la structure en unités de transcription potentielles.

Term[29,59]-promoteur[272,304]-CDS1-CDS2-CDS3-CDS4-CDS5-Term[9277,9310]-promoteur[9317,9353]-CDS6...




Figure 4 : Cartographie des CDS et structure des unités de transcription potentielles du fragment génomique

Prédiction Fonctionnelle :

Avant de commencer l'annotation fonctionnelle, le découpage des CDS du fragment et leur traduction ont été réalisés à l'aide de la suite logicielle EMBOSS, en utilisant les programmes `extractseq` (avec un choix minutieux du cadre de lecture) et `transeq`.

Seq 1 & Seq 2 :

Pour les deux premières séquences du fragment, correspondant à CDS1 et CDS2, aucune homologation n'a été trouvée avec **blastp**. Il est fort probable que ces séquences soient uniques ou peu représentées dans les bases de données, ce qui explique l'absence d'homologues connus.

Job Title	SEQ_L_LACTIS_LACTIS_455_3436_2
RID	RGA70BN4013 Search expires on 01-05 01:13 am Download All ▼
Program	Citation ▼
Database	nr See details ▼
Query ID	lcl Query_9580445
Description	SEQ_L_LACTIS_LACTIS_455_3436_2
Molecule type	amino acid
Query Length	994
Other reports	?

Filter Results

Percent Identity	E value	Query Coverage
to	to	to
Filter		Reset

⚠ No significant similarity found. For reasons why, [click here](#)

Compare these results against the new Clustered nr database [?](#) [BLAST](#) ✕

Job Title: seq_L_lactis_lactis_3447_5249_3

RID: RGAA9BWW013 [Search expires on 01-05 01:15 am](#) [Download All](#) ▼

Program: [Citation](#) ▼

Database: nr [See details](#) ▼

Query ID: lcl|Query_7746383

Description: seq_L_lactis_lactis_3447_5249_3

Molecule type: amino acid

Query Length: 601

Other reports: [?](#)

Filter Results

Percent Identity: to E value: to Query Coverage: to

[Filter](#) [Reset](#)

No significant similarity found. For reasons why [click here](#)

Compare these results against the new Clustered nr database [?](#) [BLAST](#)

Figure 5 : Résultats BlastP pour la séquence 1 & 2

Seq 3 :

Protéine de la famille des lanthionine synthétases C (LanC) similaire à la protéine de biosynthèse de nisine NisC de *Lactococcus lactis* et à la protéine de biosynthèse de subtiline SpaC de *Bacillus subtilis*.

Conserved domains on [lcl|Query_2914843] [View](#) [Standard Results](#) [?](#)

seq_L_lactis_lactis_5242_6486_1

Protein Classification

lanthionine synthetase C family protein(domain architecture ID 10141012)

lanthionine synthetase C (LanC) family protein similar to *Lactococcus lactis* nisin biosynthesis protein NisC and *Bacillus subtilis* subtilin biosynthesis protein SpaC

CATH: 1.50.10.20 [Gene Ontology: GO:0031179|GO:0005975](#) [PubMed: 23071302](#) [SCOP: 4001568](#)

Graphical summary [Zoom to residue level](#) [show extra options >](#)

Query seq.

Specific hits

LanC

LANC_like

Non-specific hits

LcnDR2

lanti_2_LanM

Superfamilies

LanC_like superfamily

LcnDR2 superfamily

[Search for similar domain architectures](#) [Refine search](#)

List of domain hits

	Name	Accession	Description	Interval	E-value
[H]	LanC	cd04793	Cyclases involved in the biosynthesis of lantibiotics; LanC is the cyclase enzyme of the ...	34-400	1.04e-97
[H]	LANC_like	pfam05147	Lanthionine synthetase C-like protein; Lanthionines are thioether bridges that are putatively ...	29-402	2.23e-70
[H]	LcnDR2	COG4403	Lantibiotic modifying enzyme [Defense mechanisms]	15-380	3.23e-23
[H]	lanti_2_LanM	TIGR03897	type 2 lantibiotic biosynthesis protein LanM; Members of this family are known generally as ...	38-380	9.35e-15

Figure 6 : Résultats BlastP & domaine spécifique pour la séquence 3

Cette protéine possède un domaine fonctionnel : C'est l'enzyme cyclase de la synthétase de lanthionine 'LanC', impliquée dans la biosynthèse des lantibiotiques. Ce domaine couvre presque la totalité de la séquence de la protéine, allant de l'intervalle 34 à 400.

Seq 4 : Protéine ,lanthionine synthetase C, appartenant à la famille des synthétases de lanthionine.




Figure 7 : Résultats BlastP pour la séquence 4

Seq 5 : Peptidase de la famille S8

La protéine identifiée appartient à la famille S8 des peptidases, qui inclut des protéases spécifiques aux lantibiotiques (antibiotiques contenant de la lanthionine). Ces protéases, structurées de manière similaire aux protéases à sérine, sont responsables de l'activation des lantibiotiques en clivant les peptides leaders N-terminaux.

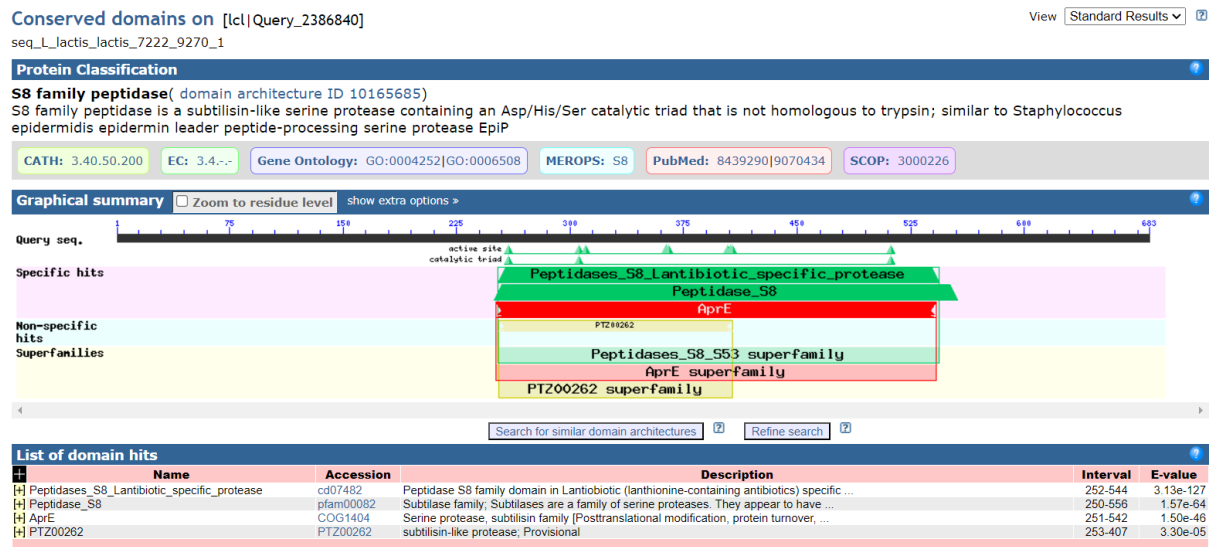



Figure 8 : Résultats BlastP & domaine spécifique pour la séquence 5

Elle possède un domaine fonctionnel de type Peptidases_S8_Lantibiotic_specific_protease situé dans la région N-terminale.

Localisation cellulaire :

Pour une analyse précise, il convient de noter que seule la séquence 5 présente un peptide signal de type Sec/SPI, indiquant qu'elle est destinée à être sécrétée par le système de sécrétion de type I.

Cleavage site between pos. 22 and 23.
Probability 0.977312



On voit que le début de la séquence a une forte probabilité associée à ce type de peptide signal . Cette probabilité chute ensuite pour être remplacée pour le reste de la séquence par une forte probabilité « other » c'est-à-dire autre qu'un des 3 types de signal peptide recherchés. La courbe verte indique la probabilité du site de coupure. Le résultat donné indique que le site de clivage est en position 22 .

Résultats obtenus :

Les quatre premières séquences ne présentent pas de régions transmembranaires, ce qui indique qu'elles ne sont pas des protéines membranaires. La séquence 5, bien qu'elle n'ait pas de TMR, contient un peptide signal, ce qui suggère qu'elle est sécrétée à l'extérieur de la cellule, typique des protéines solubles des bactéries Gram-positives comme *Lactococcus lactis*.

Informations complémentaires :

La **synthétase de lanthionine (LanC)** joue un rôle central dans la biosynthèse des lantibiotiques, une classe d'antibiotiques contenant des résidus de lanthionine. Ces enzymes catalysent la formation de ponts thioéther entre des résidus spécifiques de cystéine et de sérine/thréonine dans les peptides précurseurs. Ce processus confère une grande stabilité structurelle et est essentiel pour activer les propriétés antimicrobiennes des lantibiotiques. Ces molécules sont particulièrement efficaces contre diverses bactéries pathogènes, en perturbant leur membrane cellulaire. Un exemple typique de lantibiotique produit grâce à l'action de LanC est la nisine, largement utilisée comme conservateur alimentaire en raison de son efficacité à inhiber les bactéries Gram-positives. En outre, la biosynthèse des lantibiotiques par LanC est un mécanisme clé permettant à des bactéries comme *Lactococcus lactis* de survivre dans des environnements compétitifs, notamment au sein des communautés microbiennes alimentaires.

La **peptidase de la famille S8** est une enzyme cruciale pour la maturation des lantibiotiques. Son rôle principal consiste à cliver les peptides précurseurs en éliminant les segments non fonctionnels, permettant ainsi aux lantibiotiques de devenir pleinement actifs. Ce clivage précis est fondamental pour que ces molécules acquièrent leurs propriétés antimicrobiennes. La peptidase S8 possède un peptide signal, détecté via SignalP, qui suggère qu'elle est sécrétée dans l'environnement extracellulaire. Cela est cohérent avec sa fonction, car les lantibiotiques matures doivent interagir avec d'autres bactéries à l'extérieur de la cellule productrice. En plus de son rôle dans l'activation des lantibiotiques, cette peptidase peut être un point d'intérêt biotechnologique, notamment pour le développement de nouveaux antibiotiques ou la modification de produits fermentés.

Référence :

① Blanquet, V., & Durand, S. (n.d.). Annotation de la séquence d'ADN génomique. Encyclopædia Universalis.
<https://www.universalis.fr/encyclopedie/genomique-annotation-des-genomes/3-annotation-de-la-sequence-d-adn-genomique/>

②TP annotation d'un fragment génomique bactérien

L'intelligence artificielle a été utilisée pour surmonter certaines difficultés

Annexes :

```

utilisateur@ut3-10700041 MINGW64 ~/Documents/BG/programme_scan
$ cat res_perl_promotor.gff
"eq_l_lactis_lactis Patscan promotor 111 151 . + . note "TTGCCA TCAATGCTCAGGACGAATATTGCATGATC TATCAT
"eq_l_lactis_lactis Patscan promotor 272 304 . + . note "TTGTAA AACAGGAGCTCTGATGGGTTG TAACAT
"eq_l_lactis_lactis Patscan promotor 1175 1218 . + . note "TTGACT AAAGTTGAAGCAATAGATGAAGATAAAAAATA TATAAT
"eq_l_lactis_lactis Patscan promotor 1527 1561 . + . note "TTGATT CTACATTTGGCATAGGAGCTCCA TATAAT
"eq_l_lactis_lactis Patscan promotor 2123 2152 . + . note "TTGAAA TTCTACATTACAGCATG TACAAT
"eq_l_lactis_lactis Patscan promotor 3793 3830 . + . note "TTGAAT TAAGTGATTATGACGAGGCTGATATG TATAAT
"eq_l_lactis_lactis Patscan promotor 4242 4279 . + . note "TTGAAT TTGATAAATATTCTTACGATATTTCG TATGAT
"eq_l_lactis_lactis Patscan promotor 5103 5131 . + . note "TTGAAT GCTGCCAGAAAAGCAAA TAAAAAT
"eq_l_lactis_lactis Patscan promotor 5338 5369 . + . note "TTGACT CTCTCTACAGGATTGCCTGG TATAAT
"eq_l_lactis_lactis Patscan promotor 6571 6605 . + . note "TTGACG AAGGAAGTTATACTAATTTTATT TATGAT
"eq_l_lactis_lactis Patscan promotor 9317 9353 . + . note "TTGACT TCCGCTTGAAATCACTTGAGCATTC TACAAT

utilisateur@ut3-10700041 MINGW64 ~/Documents/BG/programme_scan
$ perl scan_for_matches_to_gff.pl D:/S1-bbs/BG/A_rendre/resultats_RBS_consensus.txt RBS res_perl_RBS.gff
Parsing completed. Output written to res_perl_RBS.gff.

utilisateur@ut3-10700041 MINGW64 ~/Documents/BG/programme_scan
$ cat res_perl_RBS.gff
"eq_l_lactis_lactis Patscan RBS 161 176 . + . note "GGAGG CACTCAA ATG
"eq_l_lactis_lactis Patscan RBS 6469 6485 . + . note "GGAGG GAAGAGGAA ATG
"eq_l_lactis_lactis Patscan RBS 8071 8086 . + . note "GGAGG GTTGATA ATG
"eq_l_lactis_lactis Patscan RBS 9397 9411 . + . note "GGAGG TAAAGTG GTG

utilisateur@ut3-10700041 MINGW64 ~/Documents/BG/programme_scan
$ cat res_perl_promotor.gff
"eq_l_lactis_lactis Patscan promotor 111 151 . + . note "TTGCCA TCAATGCTCAGGACGAATATTGCATGATC TATCAT
"eq_l_lactis_lactis Patscan promotor 272 304 . + . note "TTGTAA AACAGGAGCTCTGATGGGTTG TAACAT
"eq_l_lactis_lactis Patscan promotor 1175 1218 . + . note "TTGACT AAAGTTGAAGCAATAGATGAAGATAAAAAATA TATAAT
"eq_l_lactis_lactis Patscan promotor 1527 1561 . + . note "TTGATT CTACATTTGGCATAGGAGCTCCA TATAAT
"eq_l_lactis_lactis Patscan promotor 2123 2152 . + . note "TTGAAA TTCTACATTACAGCATG TACAAT
"eq_l_lactis_lactis Patscan promotor 3793 3830 . + . note "TTGAAT TAAGTGATTATGACGAGGCTGATATG TATAAT
"eq_l_lactis_lactis Patscan promotor 4242 4279 . + . note "TTGAAT TTGATAAATATTCTTACGATATTTCG TATGAT
"eq_l_lactis_lactis Patscan promotor 5103 5131 . + . note "TTGAAT GCTGCCAGAAAAGCAAA TAAAAAT
"eq_l_lactis_lactis Patscan promotor 5338 5369 . + . note "TTGACT CTCTCTACAGGATTGCCTGG TATAAT
"eq_l_lactis_lactis Patscan promotor 6571 6605 . + . note "TTGACG AAGGAAGTTATACTAATTTTATT TATGAT
"eq_l_lactis_lactis Patscan promotor 9317 9353 . + . note "TTGACT TCCGCTTGAAATCACTTGAGCATTC TACAAT

utilisateur@ut3-10700041 MINGW64 ~/Documents/BG/programme_scan
$ cat res_perl_term.gff
"eq_l_lactis_lactis Patscan terminateur 29 59 . + . note "AAC CCCGG ATGAGAATT CCGGG GTT TTTTTT
"eq_l_lactis_lactis Patscan terminateur 557 582 . + . note "ACT GTA AGTAAAAA TAA AGT TTTTTT
"eq_l_lactis_lactis Patscan terminateur 1771 1800 . + . note "AAA GGAGT ATGAAAAA GATAT TTT TATTTT
"eq_l_lactis_lactis Patscan terminateur 3986 4009 . + . note "AGT ATT ATCTTT GGT ACT TTTTCT
"eq_l_lactis_lactis Patscan terminateur 4404 4424 . + . note "TTG TTT ATG GAA CAA CTTTTT
"eq_l_lactis_lactis Patscan terminateur 6683 6717 . + . note "GTT GATTGTT GACATGAAA AGTGAGA AAC TTTTAT
"eq_l_lactis_lactis Patscan terminateur 7224 7248 . + . note "GAA AAA AATACTA GGT TTC CTTTTT
"eq_l_lactis_lactis Patscan terminateur 8162 8183 . + . note "TTA CAG CAAA TGG TAA TATTTT
"eq_l_lactis_lactis Patscan terminateur 8670 8696 . + . note "TAA ATT TGTCAGTCA GGG TTA TTATTT
"eq_l_lactis_lactis Patscan terminateur 9277 9310 . + . note "GAA AAAGGGT GGGAAATCC ACTCTTT TTC TTTTTT

```

Figure 10 : Résultats de transformation des résultats de scan for matches en format GFF

le pseudo-code :

1. Transformation des résultats Scan for matches en format GFF :

```

DÉBUT
// Vérifier le nombre d'arguments
SI le nombre d'arguments n'est pas égal à 3 ALORS
    AFFICHER "Usage: perl script.pl <input_file> <feature> <output_file>"
    TERMINER le programme
FIN SI
// Assignment des arguments à des variables
input_file = ARG[0]
feature = ARG[1]
output_file = ARG[2]
// Ouvrir le fichier d'entrée
ESSAYER
    OUVRIR input_file en lecture comme fh_in
SINON
    AFFICHER "Impossible d'ouvrir le fichier d'entrée"
    TERMINER le programme
FIN ESSAYER

```



```

// Ouvrir le fichier de sortie
ESSAYER
    OUVRIR output_file en écriture comme fh_out
SINON
    AFFICHER "Impossible d'ouvrir le fichier de sortie"
    TERMINER le programme
FIN ESSAYER
// Traitement du fichier d'entrée
TANT QUE ligne = LIRE fh_in FAIRE
    SUPPRIMER le retour à la ligne de ligne
    // Vérifie si la ligne commence par '>'
    SI ligne correspond à ">nom_sequence:[début,fin]" ALORS
        sequence_name = extraire nom_sequence
        start_pos = extraire début
        end_pos = extraire fin
        // Récupère la ligne suivante pour le motif
        motif_line = LIRE fh_in
        SUPPRIMER le retour à la ligne de motif_line
        // Génère la ligne GFF
        gff_line = CONCATENATE(sequence_name, "\t", "Patscan", "\t", feature, "\t",
                                start_pos, "\t", end_pos, "\t", ".", "\t", "+", "\t",
                                ".", "\t", "note \"" + motif_line + "\"")

        // Écrit la ligne dans le fichier de sortie
        ÉCRIRE gff_line dans fh_out
    FIN SI
FIN TANT QUE
// Ferme les fichiers
FERMER fh_in
FERMER fh_out
AFFICHER "Parsing completed. Output written to " + output_file
FIN

```

2. Transformation des résultats GeneMark en format GFF :

```

utilisateur@ut3-10700041 MINGW64 ~/Documents/BG
$ perl genemark_to_gff_test1.pl D:/S1-bbs/BG/A_rendre/genemark.txt seq_L_lactis_lactis
seq_L_lactis_lactis    GenMark CDS      455      3436      0.55      +      .      gene GM_CDS_1.1
seq_L_lactis_lactis    GenMark ATG      455      457      0.00      +      .
seq_L_lactis_lactis    GenMark CDS      623      3436      0.56      +      .      gene GM_CDS_1.2
seq_L_lactis_lactis    GenMark ATG      623      625      0.00      +      .
seq_L_lactis_lactis    GenMark CDS      785      3436      0.57      +      .      gene GM_CDS_1.3
seq_L_lactis_lactis    GenMark ATG      785      787      0.00      +      .
seq_L_lactis_lactis    GenMark CDS      848      3436      0.57      +      .      gene GM_CDS_1.4
seq_L_lactis_lactis    GenMark ATG      848      850      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     1310      3436      0.53      +      .      gene GM_CDS_1.5
seq_L_lactis_lactis    GenMark ATG     1310     1312      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     3447     5249      0.63      +      .      gene GM_CDS_2.1
seq_L_lactis_lactis    GenMark ATG     3447     3449      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     3456     5249      0.63      +      .      gene GM_CDS_2.2
seq_L_lactis_lactis    GenMark ATG     3456     3458      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     3561     5249      0.65      +      .      gene GM_CDS_2.3
seq_L_lactis_lactis    GenMark ATG     3561     3563      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     3630     5249      0.63      +      .      gene GM_CDS_2.4
seq_L_lactis_lactis    GenMark ATG     3630     3632      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     3687     5249      0.63      +      .      gene GM_CDS_2.5
seq_L_lactis_lactis    GenMark ATG     3687     3689      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     5230     6486      0.67      +      .      gene GM_CDS_3.1
seq_L_lactis_lactis    GenMark ATG     5230     5232      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     5239     6486      0.68      +      .      gene GM_CDS_3.2
seq_L_lactis_lactis    GenMark ATG     5239     5241      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     5242     6486      0.68      +      .      gene GM_CDS_3.3
seq_L_lactis_lactis    GenMark ATG     5242     5244      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     5374     6486      0.71      +      .      gene GM_CDS_3.4
seq_L_lactis_lactis    GenMark ATG     5374     5376      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     5653     6486      0.69      +      .      gene GM_CDS_3.5
seq_L_lactis_lactis    GenMark ATG     5653     5655      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     5806     6486      0.69      +      .      gene GM_CDS_3.6
seq_L_lactis_lactis    GenMark ATG     5806     5808      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     5827     6486      0.69      +      .      gene GM_CDS_3.7
seq_L_lactis_lactis    GenMark ATG     5827     5829      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     6483     7220      0.53      +      .      gene GM_CDS_4.1
seq_L_lactis_lactis    GenMark ATG     6483     6485      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     6507     7220      0.54      +      .      gene GM_CDS_4.2
seq_L_lactis_lactis    GenMark ATG     6507     6509      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     6564     7220      0.58      +      .      gene GM_CDS_4.3
seq_L_lactis_lactis    GenMark ATG     6564     6566      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     6696     7220      0.71      +      .      gene GM_CDS_4.4
seq_L_lactis_lactis    GenMark ATG     6696     6698      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     6738     7220      0.72      +      .      gene GM_CDS_4.5
seq_L_lactis_lactis    GenMark ATG     6738     6740      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     6789     7220      0.75      +      .      gene GM_CDS_4.6
seq_L_lactis_lactis    GenMark ATG     6789     6791      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     6873     7220      0.78      +      .      gene GM_CDS_4.7
seq_L_lactis_lactis    GenMark ATG     6873     6875      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     6939     7220      0.73      +      .      gene GM_CDS_4.8
seq_L_lactis_lactis    GenMark ATG     6939     6941      0.00      +      .
seq_L_lactis_lactis    GenMark CDS     7222     9270      0.89      +      .      gene GM_CDS_5.1
seq_L_lactis_lactis    GenMark ATG     7222     7224      0.00      +      .

```

Figure 11 : Résultats de transformation des résultats de GeneMark en format GFF

DEBUT

// Vérifier le nombre d'arguments

SI le nombre d'arguments n'est pas égal à 2 ALORS

Afficher "Usage: perl script.pl <input_file> <sequence_name>"

TERMINER

// Assigner les arguments à des variables

input_file ← ARG[0]

sequence_name ← ARG[1]

// Ouvrir le fichier d'entrée

OUVRIRE input_file EN MODE 'lecture' EN tant que fh

DECLARER cds_data comme un dictionnaire // Pour stocker les données des CDS

```

// Lire le fichier ligne par ligne
POUR chaque ligne DANS fh FAIRE
    // Ignore les lignes jusqu'à la section des prédictions
    SI la ligne commence par "Left" ALORS
        IGNORER les trois lignes suivantes
        CONTINUER À L'ITÉRATION SUIVANTE
    // Capture les données de prévision
    SI la ligne correspond au motif de prévision ALORS
        EXTRAIRE left_end, right_end, strand, coding_prob à partir de la ligne
        // Convertir le brin
        SI strand est "direct" ALORS
            gff_strand ← "+"
        SINON
            gff_strand ← "-"
        FIN SI
        // Stocker les données dans le dictionnaire
        AJOUTER un nouvel élément à cds_data avec right_end comme clé
        ET left_end, coding_prob, gff_strand comme valeurs
    FIN POUR
// Génération des lignes GFF
cds_count ← 1 // Compteur pour les CDS
POUR chaque right_end dans les clés de cds_data TRIÉES FAIRE
    version_count ← 1 // Compteur pour les versions
    POUR chaque cds_info DANS cds_data[right_end] FAIRE
        left_end ← cds_info.left_end
        coding_prob ← cds_info.coding_prob
        gff_strand ← cds_info.strand
        // Générer la ligne GFF pour le CDS
        gff_line ← construire une ligne avec sequence_name, GenMark, "CDS", left_end,
right_end, coding_prob, gff_strand et d'autres informations
        IMPRIMER gff_line
        // Vérifie et gère les codons ATG pour chaque CDS
        atg_start ← left_end
        atg_end ← atg_start + 2 // Codon ATG occupe 3 positions
        // Générer la ligne GFF pour le codon ATG
        gff_atg_line ← construire une ligne avec sequence_name, GenMark, "ATG",
atg_start, atg_end, "0.00", gff_strand
        IMPRIMER gff_atg_line
        version_count ← version_count + 1 // Incrémente le compteur de version
    FIN POUR
    cds_count ← cds_count + 1 // Incrémente le compteur de CDS
FIN POUR
// Ferme le fichier
FERMER fh
FIN

```

3. Transformation des résultats GznmMark.hmm en format GFF :

```

utilisateur@ut3-10700041 MINGW64 ~/Documents/BG
$ perl genemarkhmm_to_gff.pl D:/S1-bbs/BG/A_rendre/genemark_hmm.txt seq_L_lactis_lactis
seq_L_lactis_lactis    GeneMark    CDS    455    3436    .    +    .    ID=CDS_1    Length=2982    Class=2
seq_L_lactis_lactis    GeneMark    CDS    3447    5249    .    +    .    ID=CDS_2    Length=1803    Class=2
seq_L_lactis_lactis    GeneMark    CDS    5242    6486    .    +    .    ID=CDS_3    Length=1245    Class=2
seq_L_lactis_lactis    GeneMark    CDS    6483    7220    .    +    .    ID=CDS_4    Length=738    Class=2
seq_L_lactis_lactis    GeneMark    CDS    7222    9270    .    +    .    ID=CDS_5    Length=2049    Class=1

```

Figure 12 : Résultats de transformation des résultats de GeneMark.HMM en format GFF

```

DEBUT
// Vérifier le nombre d'arguments
SI le nombre d'arguments n'est pas égal à 2 ALORS
    Afficher "Usage: perl script.pl <input_file> <sequence_name>"
    TERMINER
// Assigner les arguments à des variables
input_file ← ARG[0]
sequence_name ← ARG[1]
// Ouvrir le fichier d'entrée
OUVRIR input_file EN MODE 'lecture' EN tant que fh
DECLARER genes comme un tableau // Pour stocker les informations des gènes
// Lire le fichier ligne par ligne
TANT QUE (ligne = lire depuis fh) FAIRE
    // Cherche la ligne qui commence par "Predicted genes"
    SI ligne contient "Predicted genes" ALORS
        // Ignore les lignes suivantes jusqu'à ce que les données commencent
        IGNORER les trois lignes suivantes
        SORTIR de la boucle
    FIN SI
FIN TANT QUE
// Lire les informations des gènes
TANT QUE (ligne = lire depuis fh) FAIRE
    SUPPRIMER le retour à la ligne depuis ligne
    SI ligne commence par ")" ALORS
        ARRÊTER de lire
    FIN SI
    // Capture les données des gènes
    SI ligne correspond au motif des gènes ALORS
        EXTRAIRE gene_number, strand, left_end, right_end, length, class à partir de la
ligne
        // Stocker les données dans le tableau
        AJOUTER un nouvel élément à genes avec les valeurs extraites
        (note : gene_number est décrémenté de 1)
    FIN SI
FIN TANT QUE
// Génération des lignes GFF
POUR chaque CDS DANS genes FAIRE
    gff_strand ← CDS.strand

```

```
left_end ← CDS.left_end
right_end ← CDS.right_end
// Générer la ligne GFF pour le gène
gff_line ← construire une ligne avec sequence_name, GeneMark, "CDS", left_end,
right_end, ".", gff_strand et d'autres informations
IMPRIMER gff_line
FIN POUR
// Ferme le fichier
FERMER fh
FIN
```
